Épico 3: Validação do prompt (Fase 3)

Histórias de Usuário

Composição da entrada

HU-301 - Como Administrador de Projeto, quero que as respostas geradas numa rodada da Fase 3 recebam o codebook completo, para que a Fase 3 meça de fato o codebook como prompt.

- A entrada de uma rodada da Fase 3 é o prompt seguido do codebook completo e do item de entrada
- O codebook completo traz, para cada definição, o título, a descrição e os critérios específicos (nome e descrição), na ordem em que aparecem no codebook
- Os critérios gerais aparecem uma vez só, num bloco próprio, e não repetidos em cada definição
- Definição sem descrição aparece só com o título, sem linha vazia no lugar da descrição
- O tipo da definição não vai à LLM
- A escala não vai à LLM, em nenhuma fase

HU-302 - Como Administrador de Projeto, quero que as rodadas da Fase 2 continuem enviando só os títulos, para que a série de rodadas continue comparável e o passado não mude.

- Uma rodada da Fase 2 monta a entrada com o prompt, os títulos e o item, como sempre montou
- Nenhuma rodada existente muda de forma de montagem por causa deste épico

HU-303 - Como Administrador de Projeto, quero que a forma de montar a entrada seja decidida pela fase em que a rodada foi criada, para que uma rodada nunca mude de natureza no meio do caminho.

- A rodada grava a fase do projeto no momento em que é criada
- A geração consulta a fase da rodada, e não a fase atual do projeto
- As rodadas criadas antes deste épico ficam registradas como Fase 2, porque é o que elas enviaram
- Como o avanço de fase exige que não haja rodada aberta, uma rodada nunca atravessa uma troca de fase

HU-304 - Como Administrador de Projeto, quero ver na lista de rodadas a qual fase cada uma pertence, para que eu leia o histórico sabendo o que cada rodada enviou à LLM.

- Cada rodada aparece com a sua fase ao lado do número

- A tela da rodada diz, em uma frase, o que foi enviado à LLM naquela fase

Entrada enviada

HU-305 - Como Administrador de Projeto, quero que cada Resposta grave o texto exato enviado à LLM, para que qualquer resposta possa ser reproduzida mesmo que a forma de montar a entrada mude um dia.

- A entrada enviada é gravada junto com o texto da resposta, na mesma escrita
- Vale para toda resposta gerada a partir deste épico, em qualquer fase
- As respostas geradas antes deste épico ficam sem entrada enviada, e a tela diz isso em vez de mostrar um campo vazio
- Uma falha de geração não grava nada, nem a entrada enviada

HU-306 - Como Administrador de Projeto, quero ler a entrada enviada de uma resposta, para que eu confira o que a LLM de fato recebeu quando uma resposta me surpreender.

- A entrada aparece na leitura da resposta, recolhida por padrão, porque é longa
- Só o Administrador vê a entrada enviada
- O texto aparece como foi enviado, sem formatação adicional

Teste de prompt

HU-307 - Como Administrador de Projeto, quero que o teste de prompt monte a entrada pela fase atual do projeto, para que na Fase 3 eu veja o codebook completo funcionando antes de abrir uma rodada.

- Nas Fases 1 e 2 o teste envia o prompt com os títulos
- Na Fase 3 o teste envia o prompt com o codebook completo
- O teste continua sem gravar nada: sem Resposta, sem Rodada, sem congelar versão

HU-308 - Como Administrador de Projeto, quero ver no teste de prompt a entrada que foi enviada, junto com a saída, para que eu entenda exatamente o que a LLM recebeu.

- A entrada aparece acima da saída, recolhida por padrão
- A entrada mostrada é a mesma que uma rodada daquela fase enviaria para aquele item
- O teste continua sujeito ao teto de respostas do projeto, como hoje

Qualidade

HU-309 - Como Administrador de Projeto, quero ver a distribuição de Alto, Médio e Baixo das notas de uma rodada da Fase 3, para que eu julgue se a LLM está produzindo o que o codebook pede.

- A distribuição aparece como porcentagem de cada ponto da escala sobre todas as notas da rodada
- Cada porcentagem vem com a contagem ao lado, para que o denominador fique à vista
- A Qualidade aparece onde o ICR já aparece para o Administrador, ao lado dele e separada dele
- A ferramenta não escreve nenhum juízo sobre o valor: nada de "boa", "ruim", "aprovada" ou cor que signifique isso

HU-310 - Como Administrador de Projeto, quero ver a Qualidade por célula, para que eu descubra em que definição e em que critério a LLM não está seguindo o codebook.

- A matriz tem a mesma forma da matriz de ICR: definições nas linhas, critérios nas colunas, critério geral valendo para todas as definições
- Cada célula mostra a distribuição das notas dela
- O par definição e critério que não existe naquela versão aparece como não aplicável
- A célula que existe e ainda não recebeu nota aparece como sem nota

HU-311 - Como Administrador de Projeto, quero ver a Qualidade ao longo das rodadas da Fase 3, para que eu saiba se o que refinei entre uma rodada e outra ajudou.

- A série tem um ponto por rodada da Fase 3, com as três porcentagens
- Cada ponto mostra a versão de codebook e a versão de prompt daquela rodada
- Nada é somado nem tirado a média entre rodadas

HU-312 - Como Administrador de Projeto, quero que a Qualidade respeite a marca de Outlier, para que a exclusão de um avaliador seja tratada do mesmo jeito nos dois números.

- Com algum avaliador marcado na rodada, a Qualidade aparece com todos e sem os marcados, juntas
- O valor com todos nunca é escondido nem substituído
- Sem marca, aparece um valor só

HU-313 - Como Administrador de Projeto, quero que a Qualidade não apareça nas rodadas da Fase 2, para que o número não me distraia numa fase em que a pergunta é outra.

- Rodadas da Fase 2 continuam mostrando só o ICR
- A comparação entre a última rodada da Fase 2 e as da Fase 3 fica possível pela exportação

HU-314 - Como Avaliador, quero não ver a Qualidade, para que minha nota não seja puxada pelo que eu imagino que o grupo está dando.

- Nenhuma tela do Avaliador mostra a Qualidade, nem durante a rodada nem depois do fechamento

- A revisão de discordâncias continua mostrando as notas uma a uma, como hoje, sem porcentagem

Série de ICR entre fases

HU-315 - Como Administrador de Projeto, quero ver o ICR das Fases 2 e 3 numa série só, para que eu veja o efeito de mandar o codebook à LLM sobre a concordância.

- A série continua com um ponto por rodada, agora com a fase ao lado da versão de codebook
- As rodadas de cada fase aparecem agrupadas visualmente
- A regra de nunca agregar versões diferentes de codebook continua valendo ponto a ponto

Orientação e mudanças entre rodadas

HU-316 - Como Administrador de Projeto, quero que a ferramenta me diga para onde olhar depois de uma rodada da Fase 3, com base no ICR, para que eu siga a ordem de leitura da fase sem decorar o método.

- Com o ICR abaixo da faixa de referência, a orientação diz que os avaliadores não estão aplicando o codebook da mesma forma e que o caminho é refinar o codebook antes de olhar a Qualidade
- Com o ICR não calculável, a orientação diz por que não há número e que a Qualidade ainda não é uma leitura confiável
- Com o ICR dentro da faixa, a orientação diz que os avaliadores concordam e que é hora de olhar a Qualidade: notas concentradas em Médio e Baixo indicam que a LLM não está seguindo o codebook, e o refinamento pode ser no prompt, no codebook ou nos dois
- A orientação lembra que mexer no codebook para ajudar a LLM também muda o que os avaliadores leem
- Em nenhum caso a orientação menciona a Fase 4 ou diz que é possível avançar
- A Qualidade continua visível nos três casos; a orientação não esconde nada

HU-317 - Como Administrador de Projeto, quero ver o que mudou de uma rodada para a seguinte, para que eu saiba a que atribuir uma diferença no ICR ou na Qualidade.

- Cada rodada, a partir da segunda do projeto, diz se a versão do codebook mudou, se a versão do prompt mudou e se a fase mudou em relação à rodada anterior
- Na primeira rodada da Fase 3 a tela diz que a mudança principal foi a forma de montar a entrada, que passou a levar o codebook completo
- Quando codebook e prompt mudaram juntos, um aviso escrito diz que não dá para atribuir a diferença a um nem ao outro
- O aviso é informação e não impede abrir a rodada

HU-318 - Como Administrador de Projeto, quero refinar o prompt e o codebook na Fase 3 do mesmo jeito que refinava o codebook na Fase 2, para que o ciclo seja um só.

- Com rodada aberta, codebook e prompt continuam travados
- Depois do fechamento, salvar sobre uma versão congelada cria a versão seguinte, como hoje
- Nenhuma trava nova depende do valor do ICR ou da Qualidade

Exportação

HU-319 - Como Administrador de Projeto, quero que o CSV da rodada traga a fase da rodada e a entrada enviada, para que a análise por fora da ferramenta consiga separar as fases e reproduzir cada resposta.

- Cada linha ganha a fase da rodada
- Cada linha ganha a entrada enviada da resposta, vazia nas respostas anteriores a este épico
- Entrada com quebra de linha, vírgula ou aspas não quebra o arquivo
- É no CSV que fica a comparação de Qualidade entre a Fase 2 e a Fase 3, já que a tela não mostra Qualidade na Fase 2

Avanço para a Fase 4

HU-320 - Como Administrador de Projeto, quero avançar para a Fase 4 quando eu julgar que o prompt está validado, para que a decisão continue sendo minha.

- O avanço exige nenhuma rodada aberta e ao menos uma rodada fechada na Fase 3
- Rodadas fechadas da Fase 2 não contam para essa pré-condição
- Nenhum valor de ICR ou de Qualidade impede o avanço
- A checagem acontece no servidor

HU-321 - Como Administrador de Projeto, quero que a ferramenta diga o que falta quando o avanço para a Fase 4 está bloqueado, para que eu não fique olhando um botão desabilitado.

- A mensagem nomeia a pré-condição que falta: a rodada aberta, com o número dela, ou a falta de rodada fechada na Fase 3
- A mensagem segue o mesmo formato das mensagens do avanço da Fase 2

HU-322 - Como Administrador de Projeto, quero uma confirmação antes de avançar, com o ICR e a Qualidade da última rodada da Fase 3 à vista, para que eu decida olhando os números sem que eles decidam por mim.

- A confirmação mostra o ICR com a faixa de referência e a distribuição da Qualidade, como informação

- A confirmação diz o que a Fase 4 é no processo e que ela congela codebook e prompt enquanto durar
- A confirmação não fala em voltar da Fase 4 para a Fase 3, porque essa ação ainda não existe
- Cancelar não muda nada

HU-323 - Como Administrador de Projeto, quero que as rodadas da Fase 3 continuem visíveis depois do avanço, para que o histórico da fase fique disponível.

- Rodadas, notas, ICR, Qualidade, marcas de outlier e anotações da Fase 3 continuam onde estão
- O painel de avanço da Fase 3 mostra que a fase foi concluída e não oferece avanço de novo

HU-324 - Como Administrador de Projeto, quero que a ferramenta não me deixe abrir rodada na Fase 4 enquanto a Fase 4 não existir, para que eu não produza dado que parece da Fase 4 e não é.

- Abrir rodada num projeto na Fase 4 é recusado com uma mensagem que diz que a Fase 4 ainda não está disponível
- A recusa acontece no servidor

Acesso e autorização

HU-325 - Como Administrador de Projeto, quero que só eu possa ver a entrada enviada, a Qualidade e a orientação, e avançar de fase, para que nada disso chegue ao Avaliador por engano.

- As ações de avanço e de leitura da entrada enviada recusam quem tem só o vínculo de avaliador
- Quem não é membro do projeto não alcança nenhuma dessas telas

HU-326 - Como Avaliador, quero avaliar na Fase 3 exatamente como avaliei na Fase 2, para que a tarefa continue sendo aplicar o codebook a uma resposta.

- A tela de avaliação não diz em que fase o projeto está
- A tela não diz que a LLM recebeu o codebook
- Fila, rótulo da resposta, escala, justificativa e envio imutável continuam iguais

Requisitos Não Funcionais

Integridade e rastreabilidade

RNF-301 - A fase da rodada é gravada na criação e nunca muda depois.

RNF-302 - A entrada enviada é gravada na mesma escrita que o texto da resposta. Não existe resposta nova sem entrada enviada.
RNF-303 - A entrada enviada guardada é exatamente a que foi passada à LLM, sem nenhuma normalização entre uma coisa e outra.
RNF-304 - Nenhum cálculo de Qualidade é gravado. Ela é derivada das notas na leitura, como o ICR.

Desempenho e custo

RNF-305 - Uma resposta da Fase 3 é mais cara do que uma da Fase 2, porque leva o codebook inteiro em cada chamada. O teto continua contando respostas, e não tokens nem dinheiro. É um risco conhecido e aceito, menor do que a dívida que o teto já tem de guardar a contagem em memória por processo.
RNF-306 - A entrada enviada acrescenta alguns KB por resposta. Com o tamanho típico de rodada, isso é desprezível.

Usabilidade e interface

RNF-307 - A Qualidade usa as mesmas palavras da escala (Alto, Médio, Baixo) e nunca palavras de juízo.
RNF-308 - A orientação é texto, não bloqueio. Nenhum botão fica desabilitado por causa dela.
RNF-309 - A entrada enviada aparece recolhida, porque é longa e é consultada só quando algo surpreende.

Segurança

RNF-310 - Toda ação nova checa o papel na camada de aplicação, com o ator vindo da sessão.
RNF-311 - Nenhuma tela do Avaliador recebe dados de Qualidade, nem escondidos. A garantia é o fluxo de controle da página não buscar esses dados para ele, como já acontece com o ICR.

Fora do Escopo

Fora deste épico, com motivo:

- **A Fase 4 em si**: coorte nova de avaliadores, congelamento de codebook e prompt durante a fase, rodada da Fase 4 e retorno da Fase 4 para a Fase 3. É épico próprio. Este épico só leva o projeto até a porta e impede rodada lá dentro enquanto ela não existir.
- **Meta de qualidade**, inclusive a declarada pelo próprio Administrador antes de ver os dados. Uma linha desenhada ao lado do número vira veredito na prática.
- **Qualquer regra de "resposta que atinge os critérios"**, como mediana por célula ou nenhuma célula em Baixo. Esse julgamento é do Administrador.
- **Qualidade nas rodadas da Fase 2**. A comparação fica pelo CSV.

- **LLM como avaliadora**. A recomendação em registro é tratá-la como lente separada, e isso pede épico próprio.
- **Saída estruturada da Resposta**, por definição.
- **Colar resposta manualmente**, prevista na ADR 0003. Na Fase 3 ela é ainda menos desejável, porque a integridade entre prompt e resposta é justamente o que a geração ao vivo garante.
- **Anonimização dos avaliadores** na revisão de discordâncias.
- **Teto por token ou por custo**. O teto continua contando respostas.
- **Reconstruir a entrada enviada das respostas antigas**. Elas ficam sem, e a tela diz isso.